

Domain Randomization for Sim-to-Sim Transfer

Ευφύης Έλεγχος, Απαλλακτική Εργασία

Κιούσης Παναγιώτης, AM: 1092647

Τσικνάκης Εμμανουήλ, AM: 1092861

22 Ιουνίου 2025

0. Περιεχόμενα

- Εισαγωγή
- Domain Randomization
- Environment
- Αρχιτεκτονική Νευρωνικού Δικτύου
- Εκπαίδευση με PPO
- Αποτελέσματα
- Πηγές

1. Εισαγωγή

Η παρούσα εργασία υλοποιεί και αξιολογεί έναν ατομικό πράκτορα (agent) ενισχυτικής μάθησης (Reinforcement Learning) σε ένα περιβάλλον συνεχούς δράσης δύο διαστάσεων. Βασικός στόχος είναι ο πράκτορας να μάθει να πλοηγείται σε έναν χώρο, προκειμένου να φτάσει αποδοτικά σε έναν δυναμικά τοποθετημένο στόχο.

Ο βασικός στόχος της εργασίας αυτής είναι η εκπαίδευση μιας πολιτικής σε ένα προσομοιωμένο περιβάλλον με τυχαιοποιημένες φυσικές παραμέτρους, όπως η μάζα, η τριβή, ο θόρυβος των αισθητήρων αλλά και η θέση του στόχου, με σκοπό τη μελέτη της γενίκευσής της σε νέες, άγνωστες παραμέτρους. Η αξιολόγηση επικεντρώνεται στη δυνατότητα μεταφοράς της πολιτικής χωρίς επανεκπαίδευση (zero-shot transfer), εξετάζοντας κατά πόσο μπορεί να ανταπεξέλθει αποτελεσματικά σε συνθήκες που δεν έχει συναντήσει κατά τη διάρκεια της εκπαίδευσης.

Το πρόβλημα προσεγγίζεται με σύγχρονες τεχνικές ενισχυτικής μάθησης, και συγκεκριμένα με τον αλγόριθμο Proximal Policy Optimization (PPO), ο οποίος αποτελεί σήμερα μία από τις πιο διαδεδομένες και αξιόπιστες μεθόδους policy-gradient. Ο πράκτορας υλοποιείται μέσω ενός Actor-Critic νευρωνικού μοντέλου, που προβλέπει τόσο την πολιτική όσο και την εκτιμώμενη τιμή κατάστασης.

Το περιβάλλον έχει σχεδιαστεί εξολοκλήρου από εμάς, χωρίς χρήση έτοιμων βιβλιοθηκών, και περιλαμβάνει ρεαλιστικά φυσικά χαρακτηριστικά όπως μάζα, τριβή και αισθητήρα τύπου LiDAR. Έχει δοθεί ιδιαίτερη έμφαση τόσο στη λειτουργικότητα όσο και στην οπτική απεικόνιση (2D & 3D visual rendering), ώστε να είναι εφικτή η παρακολούθηση και η ανάλυση της συμπεριφοράς του πράκτορα.

2. Domain randomization

Το domain randomization είναι μια τεχνική που χρησιμοποιείται κυρίως στην ενισχυτική μάθηση και τη ρομποτική, με σκοπό τη βελτίωση της γενίκευσης ενός πράκτορα. Η βασική ιδέα είναι να εισάγουμε στοχευμένη τυχαιότητα στο περιβάλλον κατά τη διάρκεια της εκπαίδευσης: κάθε επεισόδιο εκτελείται με διαφορετικές φυσικές παραμέτρους, όπως βάρος, τριβή, θέση στόχου, ένταση θορύβου στους αισθητήρες, ή ακόμα και διαφορετική διάταξη εμποδίων.

Με αυτόν τον τρόπο, ο πράκτορας εκπαιδεύεται σε μια ευρεία ποικιλία σεναρίων, αντί να προσαρμόζεται σε ένα σταθερό και περιορισμένο περιβάλλον. Αυτό ενισχύει τη robustness του και του επιτρέπει να ανταποκρίνεται ικανοποιητικά ακόμη και σε καταστάσεις που δεν έχει δει ποτέ πριν (zero-shot generalization).

Η τεχνική αυτή είναι ιδιαίτερα σημαντική σε περιπτώσεις όπου υπάρχει χάσμα μεταξύ προσομοίωσης και πραγματικού κόσμου (sim-to-real gap). Μέσω του domain randomization, η πολιτική που εκπαιδεύεται στη προσομοίωση έχει περισσότερες πιθανότητες να μεταφερθεί επιτυχώς και σε πραγματικές συνθήκες, όπου οι παράμετροι είναι ασταθείς ή αβέβαιες.

Στην εργασία μας, εφαρμόσαμε domain randomization σε κρίσιμες φυσικές παραμέτρους όπως η μάζα, η τριβή, η διάταξη στόχου, καθώς και σε χαρακτηριστικά αισθητήρων τύπου LiDAR. Αυτό ενίσχυσε την ικανότητα της πολιτικής να λειτουργεί αξιόπιστα σε διαφορετικές, απρόβλεπτες συνθήκες.

3. Environment

3.1 Αρχικοποίηση Περιβάλλοντος


Κατά την αρχικοποίηση του περιβάλλοντος, ορίζεται ο βασικός χώρος καταστάσεων και δράσεων, καθώς και τα φυσικά χαρακτηριστικά που διέπουν τη δυναμική του πράκτορα. Το περιβάλλον είναι συνεχούς φύσης και δισδιάστατο, με τον πράκτορα να κινείται στο επίπεδο xy , εντός του εύρους $[-10,10] \times [-10,10]$.

Ο χώρος παρατηρήσεων περιλαμβάνει φυσικές και γεωμετρικές παραμέτρους. Πιο συγκεκριμένα περιλαμβάνει τη σχετική θέση του στόχου (μέσω LiDAR), τη μάζα του πράκτορα και το συντελεστή τριβής.

Παράλληλα, η δράση του πράκτορα ορίζεται ως δύναμη δύο διαστάσεων που μπορεί να εφαρμοστεί σε οποιαδήποτε κατεύθυνση. Το μέγεθος της δύναμης περιορίζεται ώστε να παραμένει εντός φυσιολογικών ορίων. Αυτή η σχεδίαση παρέχει μεγαλύτερη ευελιξία στο policy που εκπαιδεύεται, συγκριτικά με διακριτούς χώρους δράσης.

Η αρχική θέση του στόχου μπορεί να ορίζεται τυχαία, ενώ ο πράκτορας ξεκινά από το μηδενικό σημείο. Η επιλογή συγκεκριμένων παραμέτρων, όπως η μάζα, η τριβή και το χρονικό βήμα (dt), αντανακλά ρεαλιστικά φυσικά μεγέθη και λειτουργεί ως βάση για την εφαρμογή domain randomization, το οποίο πραγματοποιείται σε μεταγενέστερο στάδιο (στη συνάρτηση `reset()`).

Τέλος, η αρχικοποίηση προετοιμάζει και τις απαραίτητες μεταβλητές για την οπτική απεικόνιση του περιβάλλοντος σε 2D, δίνοντας τη δυνατότητα παρακολούθησης της προόδου του πράκτορα.



3.2 Dynamics

Το σύστημά μας δέχεται ως είσοδο την δύναμη που επιδρά στον agent. Για να καθοριστεί η επομενη κατασταση του συστήματος υλοποιούμε την συνάρτηση “compute_dynamics” η οποία εφαρμόζει τους βασικούς νόμους της δυναμικής για τον προσδιορισμό της νέας θέσης και ταχύτητας του agent και συγκεκριμένα:

Direction of velocity vector:

$$\vec{d} = \frac{\vec{v}}{|\vec{v}| + 10^{-8}}$$

Friction force:

$$\overrightarrow{f_{friction}} = -friction * \vec{d},$$

όπου friction το μέτρο της τριβής.

Acceleration:

$$\vec{a} = \frac{\vec{F} + \overrightarrow{f_{friction}}}{m}$$

Velocity update:

$$\overrightarrow{v_{new}} = \vec{v} + \vec{a} \cdot \Delta t$$

Position update:

$$\overrightarrow{x_{new}} = \vec{x} + \vec{v} \cdot \Delta t + \frac{1}{2} \vec{a} \cdot \Delta t^2$$

3.3 Ανίχνευση Στόχου

Προκειμένου το σύστημα να είναι πιο ρεαλιστικό, υποθέτουμε οτι ο agent δεν ξέρει που βρίσκεται ο στόχος αλλά είναι εξοπλισμένος με ένα LiDAR που σκανάρει τον χώρο.

Η συνάρτηση lidar προσομοιώνει τη λειτουργία του LiDAR σε δισδιάστατο χώρο. Ο σκοπός της είναι να εντοπίσει και να μετρήσει την απόσταση και τη γωνία προς σταθερά σημεία αναφοράς (στη περίπτωση μας μόνο του στόχου) με βάση τη θέση του πράκτορα (position).

Για τη ρεαλιστική προσομοίωση μετρητικού οργάνου, στις μετρήσεις προστίθεται Gaussian θόρυβος.

Για κάθε landmark, αν η απόσταση είναι μικρότερη από ένα μέγιστο εύρος (max_range), τότε η ανίχνευση αποθηκεύεται. Το αποτέλεσμα είναι μια λίστα από ανιχνεύσεις, καθεμία από τις οποίες περιέχει την απόσταση, τη γωνία, και το ID του αντίστοιχου landmark.

3.4 Υπολογισμός Reward

Το σύστημα επιβράβευσης αποτελεί κρίσιμο στοιχείο για την επιτυχή εκπαίδευση του πράκτορα, καθώς διαμορφώνει τη μαθησιακή συμπεριφορά προς την επιθυμητή κατεύθυνση. Η υλοποιημένη συνάρτηση reward συνδυάζει τρεις βασικές συνιστώσες:

Αρνητική Συνιστώσα Απόστασης: Η κύρια κατευθυντήριος συνιστώσα του reward είναι η αρνητική απόσταση από τον στόχο (-distance), η οποία ενθαρρύνει τον πράκτορα να μειώνει συνεχώς την ευκλείδεια απόσταση προς τον προορισμό. Αυτή η συνιστώσα παρέχει σταθερή καθοδήγηση προς τη σωστή κατεύθυνση.

Θετική Συνιστώσα Κατευθυντικής Συμφωνίας: Για την προώθηση αποτελεσματικής πλοήγησης, το reward ενισχύεται με μια θετική συνιστώσα που υπολογίζεται από το εσωτερικό γινόμενο μεταξύ της κανονικοποιημένης δράσης και της κανονικοποιημένης κατεύθυνσης προς τον στόχο. Αυτή η συνιστώσα λαμβάνει τιμές στο διάστημα $[-1, 1]$ και επιβραβεύει δράσεις που είναι ευθυγραμμισμένες με την επιθυμητή κατεύθυνση κίνησης.

Μπόνους Επιτυχίας: Όταν ο πράκτορας φτάσει εντός της κρίσιμης ακτίνας του στόχου (threshold), λαμβάνει σημαντικό μπόνους +100. Αυτή η επιβράβευση σηματοδοτεί την επιτυχή ολοκλήρωση της αποστολής και ενισχύει τη μαθησιακή συμπεριφορά που οδηγεί σε επιτυχή αποτελέσματα.

3.5 Αλληλεπίδραση Πράκτορα με το Περιβάλλον

Η συνάρτηση step υλοποιεί τη βασική λογική της αλληλεπίδρασης του πράκτορα με το περιβάλλον σε κάθε χρονικό βήμα. Πιο συγκεκριμένα, δέχεται ως είσοδο μια δράση (δύναμη) και επιστρέφει την παρατήρηση (observation), την επιβράβευση (reward) και μια ένδειξη τερματισμού του επεισοδίου (done).

Αρχικά, η δράση περιορίζεται στο επιτρεπτό εύρος. Έπειτα, η υπολογιζόμενη δύναμη περνάει στη `compute_dynamics` για την ενημέρωση της θέσης και ταχύτητας του πράκτορα, λαμβάνοντας υπόψη τη φυσική του συστήματος. Η θέση περιορίζεται ώστε να παραμένει εντός των προκαθορισμένων ορίων.

Στη συνέχεια, ενεργοποιείται ο αισθητήρας LiDAR για την ανίχνευση του στόχου. Αν υπάρξει έγκυρη ανίχνευση, εξάγονται η απόσταση και η γωνία προς τον στόχο, οι οποίες μετατρέπονται σε καρτεσιανές συνιστώσες (dx, dy). Αυτές, μαζί με τις φυσικές παραμέτρους του πράκτορα (μάζα και τριβή), συγκροτούν το διάνυσμα παρατήρησης που επιστρέφεται στον πράκτορα.

Αμέσως μετά, υπολογίζεται η επιβράβευση του πράκτορα μέσω της `compute_reward()`, όπως παρουσιάστηκε παραπάνω.

Το επεισόδιο τερματίζεται είτε αν ο πράκτορας φτάσει στο στόχο είτε αν εξαντληθεί ο μέγιστος αριθμός βημάτων.

3.6 3D Visualization

Για την παρακολούθηση της εκπαίδευσης του πράκτορα, υλοποιήθηκε ένα σύστημα 3D οπτικοποίησης με τις βιβλιοθήκες pygame και OpenGL.

Η συνάρτηση `init_pygame_3d()` δημιουργεί παράθυρο 1000×800 με υποστήριξη OpenGL. Εφαρμόζεται προοπτική προβολή (fov 45°, βάθος 0.1–100), ενώ η κάμερα τοποθετείται με τέτοιο τρόπο ώστε να προσφέρει προοπτική θέαση του δισδιάστατου επιπέδου ως "σκηνή" σε 3D χώρο.

Ο φωτισμός ενεργοποιείται μέσω του `GL_LIGHT0`, με πηγή στις (10, 10, 20) και ρυθμισμένες παραμέτρους ambient, diffuse και specular. Τα αντικείμενα διαθέτουν υλικά με κατάλληλες ιδιότητες ανάκλασης και shininess για ρεαλιστική εμφάνιση.

Ένα space-themed background φορτώνεται με pygame και μετατρέπεται σε OpenGL texture. Η σχεδίαση γίνεται με την `draw_background()`, η οποία χρησιμοποιεί orthographic προβολή και απενεργοποιεί προσωρινά φωτισμό και βάθος.

Το περιβάλλον περιλαμβάνει:


- Έδαφος: Η `draw_ground()` δημιουργεί έδαφος με διαστάσεις [-10, 10] και ύψος 1 μονάδα, από quads με σωστούς normal vectors.
- Κύλινδροι: Ο πράκτορας και ο στόχος αναπαρίστανται ως κύλινδροι με ακτίνα και ύψος 0.4, μέσω της `draw_cylinder()` και της GLU βιβλιοθήκης.

Η `draw_shadow()` δημιουργεί ημιδιαφανείς σκιές ως γκρι disks λίγο πάνω από το έδαφος για αποφυγή z-fighting.

Κάθε αντικείμενο έχει διαφορετικές υλικές ιδιότητες:

- Πράκτορας: Μπλε (0.1, 0.1, 1.0), shininess 50.0
- Στόχος: Κόκκινο (1.0, 0.1, 0.1), shininess 30.0
- Έδαφος: Γκρι-μπλε (0.3, 0.35, 0.45), shininess 10.0

Η `render_3d()` ενσωματώνει όλα τα παραπάνω: καθαρισμός buffers, σχεδίαση background, εδάφους, σκιών και αντικειμένων. Τέλος, ενημερώνεται το display buffer και εφαρμόζεται περίοδος ανανέωσης 10ms.



4. Αρχιτεκτονική Νευρωνικού Δικτύου

4.1 Actor-Critic Μοντέλο

Για την επίλυση του προβλήματος πλοήγησης, υιοθετήθηκε η αρχιτεκτονική Actor-Critic, η οποία συνδυάζει τα πλεονεκτήματα των μεθόδων βασισμένων σε αξία (value-based) και των μεθόδων βασισμένων σε πολιτική (policy-based). Το μοντέλο αποτελείται από κοινά επίπεδα (shared layers) και δύο εξειδικευμένες κεφαλές: τον Actor για την παραγωγή πολιτικής δράσης και τον Critic για την εκτίμηση της αξίας κατάστασης.

Η κοινή αρχιτεκτονική περιλαμβάνει ένα γραμμικό επίπεδο που μετασχηματίζει τις παρατηρήσεις ($obs_dim = 4$) σε αναπαράσταση 64 διαστάσεων, ακολουθούμενο από συνάρτηση ενεργοποίησης Tanh (για μη γραμμικότητα). Αυτή η κοινή αναπαράσταση εξυπηρετεί τόσο την εκμάθηση πολιτικής όσο και την εκτίμηση αξίας.

Ο Actor αποτελείται από δύο γραμμικά επίπεδα με ενδιάμεση Tanh ενεργοποίηση, παράγοντας logits για τις δύο διαστάσεις δράσης ($act_dim = 2$). Η εξαγωγή του Actor χρησιμοποιείται ως μέση τιμή για την κατανομή Normal που μοντελοποιεί την πολιτική δράσης. Παράλληλα, ο Critic ακολουθεί παρόμοια δομή, παράγοντας μια μοναδική τιμή που αντιπροσωπεύει την μακροπρόθεσμη αναμενόμενη ανταμοιβή (εκτιμώμενη αξία της τρέχουσας κατάστασης).

4.2 Χώρος Παρατηρήσεων

Το διάνυσμα παρατηρήσεων σχεδιάστηκε ώστε να παρέχει στον πράκτορα την απαραίτητη πληροφορία για αποτελεσματική πλοήγηση. Συγκεκριμένα, το διάνυσμα παρατήρησης αποτελείται από τέσσερις διαστάσεις:

- **Σχετική θέση στόχου (dx, dy):** Οι καρτεσιανές συνιστώσες της σχετικής θέσης του στόχου, όπως αυτές προκύπτουν από τη μετατροπή των πολικών μετρήσεων του LiDAR. Αυτές οι συνιστώσες υπολογίζονται ως $dx = \text{distance} \times \cos(\text{angle})$ και $dy = \text{distance} \times \sin(\text{angle})$.
- **Μάζα πράκτορα (mass):** Η μάζα του πράκτορα, η οποία επηρεάζει τη δυναμική συμπεριφορά του συστήματος σύμφωνα με τους νόμους της κίνησης. Η συμπερίληψη αυτής της παραμέτρου επιτρέπει στον πράκτορα να προσαρμόζει τη στρατηγική του ανάλογα με τα φυσικά χαρακτηριστικά του.
- **Συντελεστής τριβής (friction):** Ο συντελεστής τριβής που καθορίζει την αντίσταση κίνησης, επηρεάζοντας τη δυναμική απόκριση του πράκτορα στις εφαρμοζόμενες δυνάμεις.

Η επιλογή αυτού του συμπαγούς χώρου παρατηρήσεων βασίζεται στην αρχή της ελαχιστοποίησης της πολυπλοκότητας διατηρώντας την απαραίτητη πληροφορία. Αντί να παρέχονται απευθείας οι απόλυτες συντεταγμένες πράκτορα και στόχου, η σχετική θέση προσφέρει translation invariance, ενώ η φυσική παραμετροποίηση επιτρέπει την προσαρμογή σε διαφορετικές δυναμικές συνθήκες.

5. Εκπαίδευση με Proximal Policy Optimization (PPO)

5.1 Αλγόριθμος PPO και παράμετροι

Για την εκπαίδευση του Actor-Critic μοντέλου επιλέχθηκε ο αλγόριθμος Proximal Policy Optimization (PPO), ο οποίος συνδυάζει τα πλεονεκτήματα των trust region μεθόδων με απλότητα υλοποίησης, χρησιμοποιώντας clipping στο policy ratio για την αποφυγή υπερβολικά μεγάλων αλλαγών.

Οι βασικές παράμετροι του αλγορίθμου ορίστηκαν ως εξής:

- **Epochs:** 200 συνολικά epochs εκπαίδευσης
- **Learning Rate:** 1×10^{-4} με exponential decay (StepLR scheduler, $\gamma=0.8$ κάθε 10 epochs)
- **Steps per Epoch:** 1024 βήματα αλληλεπίδρασης ανά epoch
- **Mini-batch Size:** 64 δείγματα ανά mini-batch
- **Clip Epsilon:** 0.1 για τον περιορισμό του policy ratio
- **Discount Factor (γ):** 0.99 για τον υπολογισμό των returns
- **GAE Lambda (λ):** 0.95 για το Generalized Advantage Estimation

5.2 Δυναμική Προσαρμογή Εξερεύνησης

Ένα σημαντικό χαρακτηριστικό της υλοποίησης είναι η δυναμική προσαρμογή της εξερεύνησης κατά τη διάρκεια της εκπαίδευσης. Η τυπική απόκλιση (standard deviation) της κατανομής δράσης μειώνεται γραμμικά από 0.5 στην αρχή της εκπαίδευσης σε 0.1 στο τέλος, σύμφωνα με τον τύπο:

$$std = std_{initial} - (std_{initial} - std_{final}) * epoch / total\ epochs$$

Αυτή η προσέγγιση επιτρέπει στον πράκτορα να διερευνά εκτενώς τον χώρο δράσεων στα αρχικά στάδια, ενώ σταδιακά αρχίζει να “εμπιστεύεται” περισσότερο την έξοδο του νευρωνικού καθώς η πολιτική εξελίσσεται και βελτιώνεται.

5.3 Βρόχος Εκπαίδευσης και Συλλογή Δεδομένων

Κατά τον κύριο βρόχο εκπαίδευσης ο πράκτορας αλληλεπιδρά με το περιβάλλον για 1024 βήματα ανά epoch, συλλέγοντας trajectories εμπειρίας. Κατά τη διάρκεια αυτής της φάσης, αποθηκεύονται:

- **Παρατηρήσεις** (obs_buf): Οι καταστάσεις του περιβάλλοντος
- **Δράσεις** (act_buf): Οι επιλεγμένες δράσεις του πράκτορα
- **Log Probabilities** (logp_buf): Οι αρχικές πιθανότητες των δράσεων
- **Εκτιμήσεις Αξίας** (val_buf): Οι προβλέψεις του Critic
- **Rewards** (rew_buf): Οι ληφθείσες επιβραβεύσεις
- **Done Flags** (done_buf): Οι ενδείξεις τερματισμού επεισοδίων

Η συλλογή δεδομένων συνοδεύεται από καταμέτρηση επιτυχιών (success_count), η οποία αυξάνεται όταν ο πράκτορας φτάνει εντός της κρίσιμης ακτίνας του στόχου.

5.4 Υπολογισμός Returns και Advantage Estimation

Μετά τη συλλογή των δεδομένων, υπολογίζονται τα returns χρησιμοποιώντας το Generalized Advantage Estimation (GAE) αλγόριθμο. Ο GAE αποτελεί μια εξελιγμένη τεχνική που αντιμετωπίζει το κλασικό trade-off μεταξύ bias και variance στις εκτιμήσεις advantage:

- **Monte Carlo returns:** Έχουν υψηλή διασπορά (variance) αλλά χαμηλό bias
- **Temporal Difference (TD) methods:** Έχουν χαμηλή variance αλλά υψηλότερο bias
- **GAE:** Συνδυάζει τις δύο προσεγγίσεις μέσω της παραμέτρου λ ($\lambda=1$ αντιστοιχεί σε MC, $\lambda=0$ σε TD)

Για κάθε χρονικό βήμα, υπολογίζεται ένα σφάλμα TD (delta), που εκφράζει τη διαφορά μεταξύ της πραγματικής επιβράβευσης και της πρόβλεψης του μοντέλου. Η GAE χρησιμοποιεί αυτό το σφάλμα με εκθετική εξομάλυνση (μέσω των υπερπαραμέτρων γ και λ) ώστε να παραχθεί το τελικό advantage.

1. Temporal Difference (TD) Error (δ):

$$\delta_t = r_t + \gamma \cdot V(s_t + I) \cdot (1 - d_t) - V(s_t)$$

όπου d_t είναι 1 αν το επεισόδιο τελείωσε (done), αλλιώς 0.

Αν είναι done, τότε:

$$\delta_t = r_t - V(s_t)$$

2. Generalized Advantage Estimation (GAE):

$$\widehat{A}_t = \delta_t + \gamma \lambda (1 - d_t) \cdot \widehat{A}_{t+1}$$

Αυτό είναι επαναληπτικός υπολογισμός από το τέλος της τροχιάς προς την αρχή.

3. Επιστροφές (Returns)

$$return_t = \widehat{A}_t + V(s_t)$$

Τα advantages κανονικοποιούνται με αφαίρεση του μέσου όρου και διαίρεση με την τυπική απόκλιση, τεχνική που βελτιώνει τη σταθερότητα της εκπαίδευσης και επιταχύνει τη σύγκλιση του αλγορίθμου.

5.5 Ενημέρωση Πολιτικής με PPO

Η εκπαίδευση βασίζεται στο **advantage**, το οποίο εκφράζει τη διαφορά μεταξύ της πραγματικά ληφθείσας απόδοσης (return) και της προβλεπόμενης από τον Critic (value). Ένα θετικό advantage σημαίνει ότι η απόδοση ήταν καλύτερη του αναμενομένου, άρα ο πράκτορας πρέπει να ενισχύσει την πιθανότητα αυτής της δράσης. Αντίθετα, ένα αρνητικό advantage υποδηλώνει αποτυχία και επομένως η πιθανότητα της δράσης πρέπει να μειωθεί.

Ο PPO υλοποιεί αυτές τις ενημερώσεις, αποφεύγοντας μεγάλες αλλαγές που μπορεί να αποσταθεροποιήσουν την εκπαίδευση. Για τον σκοπό αυτό, υπολογίζεται πρώτα ο **λόγος πιθανότητας** (ratio) μεταξύ της νέας και της αρχικής πολιτικής:

$$ratio = \pi_{new}(a | s) / \pi_{old}(a | s) = \exp(\log \pi_{new} - \log \pi_{old})$$

Αυτός ο λόγος δείχνει πώς έχει αλλάξει η πιθανότητα της δράσης. Αν ο λόγος είναι >1 , η νέα πολιτική θεωρεί την δράση πιο πιθανή, ενώ αν είναι <1 , λιγότερο πιθανή.

Η **PPO clipped objective** χρησιμοποιεί δύο εκδοχές του surrogate loss:

- **Surrogate₁**: Το απλό $\text{ratio} \times \text{advantage}$
- **Surrogate₂**: Το περιορισμένο ratio εντός $[1-\epsilon, 1+\epsilon] \times \text{advantage}$

Κατά την εκπαίδευση, οι εμπειρίες που συλλέγονται από το rollout ανακατεύονται τυχαία και χωρίζονται σε mini-batches μεγέθους 64. Πάνω σε κάθε mini-batch εφαρμόζεται η διαδικασία ενημέρωσης, η οποία επαναλαμβάνεται 10 φορές ανά epoch για να επιτευχθεί σταθερή σύγκλιση. Σε κάθε τέτοια επανάληψη, υπολογίζονται τρεις συνιστώσες απώλειας:

Policy Loss:

$$\text{Policy Loss} = -\min(\text{surrogate}_1, \text{surrogate}_2)$$

Βάζουμε το συγκεκριμένο policy loss επειδή το νευρωνικό δίκτυο προσπαθεί να ελαχιστοποιήσει το loss, δηλαδή να μεγιστοποιήσει το surrogate objective (ενίσχυση καλών ενεργειών). Άρα όσο πιο **αρνητικό** είναι το policy loss, τόσο **καλύτερη** θεωρείται η ενημέρωση για την πολιτική.

Value Loss: Μέσο τετραγωνικό σφάλμα μεταξύ των εκτιμήσεων αξίας και των υπολογισμένων returns.

Entropy: Η εντροπία μετρά την αβεβαιότητα της πολιτικής. Υψηλή εντροπία σημαίνει ότι η πολιτική κατανέμει ομοιόμορφα τις πιθανότητες μεταξύ των διαθέσιμων δράσεων, ενώ χαμηλή εντροπία δείχνει αποφασιστικότητα και μειωμένη εξερεύνηση. Η ενθάρρυνση της εντροπίας αποτρέπει τον πρόωρο εγκλωβισμό σε τοπικά βέλτιστα, προωθώντας πιο ανθεκτική συμπεριφορά, ιδίως κατά τα πρώτα στάδια της εκπαίδευσης.

Η συνολική απώλεια συνδυάζει τις τρεις συνιστώσες:

$$\text{Loss} = \text{Policy Loss} + 0.5 \times \text{Value Loss} - 0.01 \times \text{Entropy}$$

Αυτή η διαδικασία ενσωματώνει βασικές αρχές των policy gradient μεθόδων, προσφέροντας έναν τρόπο ενημέρωσης της πολιτικής με γνώμονα τη σταθερότητα και την αποτελεσματικότητα της εκπαίδευσης.

5.6 Παρακολούθηση Προόδου και Early Stopping

Η εκπαίδευση εκτελείται για πολλαπλά επεισόδια (epochs) και παρακολουθείται μέσω του μέσου όρου των rewards ανά epoch. Υλοποιείται μηχανισμός early stopping με patience ίσο με το 25% των συνολικών epochs (50 epochs). Όταν ένα νέο καλύτερο μοντέλο εντοπίζεται, αποθηκεύεται το state dictionary του για μετέπειτα χρήση.

Κατά τη διάρκεια των τελευταίων epochs (90% της εκπαίδευσης), ενεργοποιείται η 3D οπτικοποίηση κάθε 5 βήματα, επιτρέποντας την οπτική παρακολούθηση της συμπεριφοράς του εκπαιδευόμενου πράκτορα.

Η εκπαίδευση ολοκληρώνεται είτε με την ολοκλήρωση όλων των epochs είτε με την ενεργοποίηση του early stopping, εξασφαλίζοντας αποτελεσματική χρήση υπολογιστικών πόρων και αποφυγή overfitting.


Παρακάτω φαίνεται κατά τη διαδικασία εκτέλεσης πως εξελίσσονται τα average rewards ανα epoch.

```
🔥 New best model at epoch 18 with avg reward 3.07
Epoch 18 completed. Avg reward: 3.07
Epoch 19 completed. Avg reward: 3.00
🔥 New best model at epoch 20 with avg reward 3.20
Epoch 20 completed. Avg reward: 3.20
🔥 New best model at epoch 21 with avg reward 3.37
Epoch 21 completed. Avg reward: 3.37
🔥 New best model at epoch 22 with avg reward 3.59
Epoch 22 completed. Avg reward: 3.59
Epoch 23 completed. Avg reward: 3.41
Epoch 24 completed. Avg reward: 1.82
Epoch 25 completed. Avg reward: 2.35
Epoch 26 completed. Avg reward: 2.40
Epoch 27 completed. Avg reward: 3.05
Epoch 28 completed. Avg reward: 2.55
Epoch 29 completed. Avg reward: 3.09
Epoch 30 completed. Avg reward: 3.26
Epoch 31 completed. Avg reward: 2.99
🔥 New best model at epoch 32 with avg reward 3.97
Epoch 32 completed. Avg reward: 3.97
Epoch 33 completed. Avg reward: 3.39
🔥 New best model at epoch 34 with avg reward 4.59
Epoch 34 completed. Avg reward: 4.59
🔥 New best model at epoch 35 with avg reward 4.97
Epoch 35 completed. Avg reward: 4.97
Epoch 36 completed. Avg reward: 4.26
Epoch 37 completed. Avg reward: 3.92
Epoch 38 completed. Avg reward: 4.59
Epoch 39 completed. Avg reward: 3.62
Epoch 40 completed. Avg reward: 3.76
Epoch 41 completed. Avg reward: 3.16
Epoch 42 completed. Avg reward: 3.83
🔥 New best model at epoch 43 with avg reward 5.18
Epoch 43 completed. Avg reward: 5.18
Epoch 44 completed. Avg reward: 3.07
```


6. Αποτελέσματα

Όπως φαίνεται και στο αντίστοιχο γράφημα, η πολιτική του πράκτορα βελτιώνεται προοδευτικά με την πάροδο των εποχών. Στα διαγράμματα που ακολουθεί, παρουσιάζεται η πορεία του μέσου reward ανά epoch. Παρατηρείται σαφής τάση βελτίωσης κατά την εκπαίδευση, με τα rewards να σταθεροποιούνται σε θετικές τιμές μετά τις πρώτες 20–40 εποχές, υποδεικνύοντας ότι ο πράκτορας έχει μάθει να πλησιάζει αποτελεσματικά τον στόχο του.

με 100 εποχές:



με 200 εποχές:



Αφού ολοκληρωθεί η διαδικασία εκπαίδευσης, δοκιμάζουμε το καλύτερο μοντέλο του Policy σε 10 περιβάλλοντα με τυχαίες παραμέτρους για να αξιολογήσουμε το zero-shot transfer.

Όπως φαίνεται και τα 2 policy αποδίδουν αρκετά καλά (υψηλό ποσοστό επιτυχίας), με το 2ο μοντέλο το οποίο εκπαιδεύτηκε για 200 epochs να έχει ποσοστό επιτυχίας 100%

```

Epoch 100 completed. Avg reward: 5.11
✅ Loaded best model from memory for testing

Zero-shot generalization test on 5 unseen dynamics envs:
❌ Test 1: Failure (dist=0.329, steps=300)
Final distance: 0.329
✅ Test 2: Success
Final distance: 0.069
❌ Test 3: Failure (dist=0.351, steps=300)
Final distance: 0.351
✅ Test 4: Success
Final distance: 0.249
✅ Test 5: Success
Final distance: 0.195
✅ Test 6: Success
Final distance: 0.230
✅ Test 7: Success
Final distance: 0.277
✅ Test 8: Success
Final distance: 0.205
✅ Test 9: Success
Final distance: 0.215
✅ Test 10: Success
Final distance: 0.269

Zero-shot generalization success rate: 8/10 (80.0%)

```

```

Epoch 200 completed. Avg reward: 6.64
✅ Loaded best model from memory for testing

Zero-shot generalization test on 5 unseen dynamics envs:
✅ Test 1: Success
Final distance: 0.112
✅ Test 2: Success
Final distance: 0.114
✅ Test 3: Success
Final distance: 0.090
✅ Test 4: Success
Final distance: 0.048
✅ Test 5: Success
Final distance: 0.067
✅ Test 6: Success
Final distance: 0.102
✅ Test 7: Success
Final distance: 0.235
✅ Test 8: Success
Final distance: 0.115
✅ Test 9: Success
Final distance: 0.246
✅ Test 10: Success
Final distance: 0.115



Zero-shot generalization success rate: 10/10 (100.0%)

```

Παρακάτω φαίνονται τα αποτελέσματα των test runs στο διδιάστατο περιβάλλον.

Με μπλε χρώμα εμφανίζονται οι agents που κατάφεραν να φτάσουν στο στόχο σε απόσταση μικρότερη από το threshold ($=0.3$), ενώ με κόκκινο αυτοί που δεν κατάφεραν.

Στο σχήμα φαίνεται επίσης η τελική θέση του στόχου.



Τα παραπάνω αποτελέσματα δείχνουν πως η πολιτική κατάφερε να μάθει μια στρατηγική πλοήγησης που είναι σταθερή και αποδοτική, ακόμα και σε τυχαιοποιημένα περιβάλλοντα που δεν είχε ξαναδεί. Η επιτυχία στις zero-shot δοκιμές αποδεικνύει ότι το domain randomization συνέβαλε ουσιαστικά στη γενίκευση του πράκτορα.

7.Πηγές

1. Tobin, J., Fong, R., Ray, A., Schneider, J., Zaremba, W. and Abbeel, P., 2017, September. Domain randomization for transferring deep neural networks from simulation to the real world. In 2017 IEEE/RSJ international conference on intelligent robots and systems (IROS) (pp. 23-30). pdf
2. Schulman, J., Wolski, F., Dhariwal, P., Radford, A., & Klimov, O. (2017). *Proximal Policy Optimization Algorithms*. arXiv preprint arXiv:1707.06347. <https://arxiv.org/abs/1707.06347>
3. <https://lilianweng.github.io/posts/2018-04-08-policy-gradient/>
4. Διαφάνειες μαθήματος
5. Chat GPT (με έρευνα για τεκμηρίωση)